



## 저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩 士 學 位 論 文

LSTM 기반의 딥러닝을 이용한  
한반도 지역의 구름 이미지 및  
일사량 지도 예측

高麗大學校 大學院

産業經營工學科

朴 成 訓

2020 年 8 月

韓盛元 教授指導

碩 士 學 位 論 文

LSTM 기반의 딥러닝을 이용한  
한반도 지역의 구름 이미지 및  
일사량 지도 예측

이 論文을 工學 碩士學位 論文으로 提出함.

2020 年 8 月

高 麗 大 學 校 大 學 院

産業經營工學科

朴 成 訓



朴 成 訓 의 工學 碩士學位 論文  
審査를 完了함.

2020 年 8 月

委員長 한 성 원. (인)


委 長 김 성 범. (인)

委 長 강 필 성. (인)



## Abstract

Solar energy has steadily attracted attention as a natural energy source, which has led to the development of efficient and easy-to-install systems. The amount of solar power generated in a specific area is mainly affected by isolation, which is affected by the amount of clouds in the area. Thus, if the cloud movement can be predicted, the amount of power generation in a particular region can also be predicted, which is a critical factor to satisfy the electricity demand of the region. Therefore, in this study, we attempted to predict cloud movement by using a solar radiation map, wherein the pixel value indicates the normalized isolation value, known as the clear sky index. First, we implemented the cross-correlation method to predict the movement of clouds and produce an isolation map of the next time step. Next, the challenge was defined as forecasting the next frame solar radiation map based on past frames, known as video prediction. We implemented various deep learning models, FC-LSTM, ConvLSTM, PredRNN, and PredRNN++, to predict the next time step cloud image. Moreover, we achieved higher performance forecasting using the model to make final predictions by applying the results of the deep learning models as input to an auto-encoder. Unlike the cross-correlation-based method, the deep learning-based method has the advantage of showing the direction of cloud movement more



intuitively. Furthermore, this method allows us to understand the change in solar radiation over the entire Korean Peninsula precisely, which can provide essential information to enable efficient energy generation.

Keywords: cloud, solar radiation, movement, cross-correlation, deep learning, next frame prediction



## 목차

|                                             |    |
|---------------------------------------------|----|
| 1. 서론 및 선행연구.....                           | 1  |
| 2. 데이터 구성 및 전처리 .....                       | 7  |
| 2.1 데이터 구성.....                             | 7  |
| 2.2 데이터 전처리 .....                           | 8  |
| 3. 방법론.....                                 | 10 |
| 3.1 교차 상관 기법 .....                          | 10 |
| 3.2 LSTM 기반 딥러닝 모델.....                     | 12 |
| 3.3 스택킹을 이용한 제안모델 .....                     | 22 |
| 4. 실험 설계.....                               | 25 |
| 4.1 교차 상관 기법 구현.....                        | 25 |
| 4.2 구름의 이동방향 예측 (CV vs Deep learning) ..... | 26 |
| 4.3 일사량 지도 생성 .....                         | 27 |
| 5. 실험 결과.....                               | 29 |
| 5.1 평가 지표.....                              | 29 |
| 5.1 구름의 이동방향 예측 결과 비교 .....                 | 31 |
| 5.2 일사량 지도 생성 결과 비교 .....                   | 33 |
| 6. 결론 .....                                 | 38 |
| 참고 문헌 .....                                 | 40 |



## List of figures

|                                                                                        |    |
|----------------------------------------------------------------------------------------|----|
| Figure 1. (a): 원본 데이터 영역 및 위성 영상 (b) 본 연구에서 사용한<br>128×128 사이즈의 일사량 지도 예시 .....        | 9  |
| Figure 2. 교차 상관 기법 프로세스 .....                                                          | 11 |
| Figure 3. 향후 5 시점 동안 동일한 이동 벡터가 유지되는 현재의 예보시스템<br>.....                                | 12 |
| Figure 4. FC-LSTM 아키텍처 (Ranzato, M et al., 2014) .....                                 | 14 |
| Figure 5. ConvLSTM 셀 구조 .....                                                          | 15 |
| Figure 6. PredRNN의 구조 .....                                                            | 18 |
| Figure 7. PredRNN++ 구조 .....                                                           | 20 |
| Figure 8. 본 연구에서의 스택킹 적용 프로세스, G는 입력 이미지 수, N은<br>출력 이미지 수 .....                       | 22 |
| Figure 9. 메타모델로 사용된 UNet 벤치마킹의 합성곱 오토인코더 구조 .....                                      | 24 |
| Figure 10. 첫번째, 두번째 이미지를 이용하여 구한 벡터가 미래의 8 시점<br>동안 유지된다고 가정한 뒤 구한 각 프레임별 MSE 평균 ..... | 32 |
| Figure 11. 교차 상관 기법 vs 딥러닝 모델 .....                                                    | 33 |
| Figure 12. 각 프레임별 딥러닝 모델들의 MSE 값 비교 .....                                              | 35 |
| Figure 13. 각 프레임별 딥러닝 모델들의 PSNR 값 비교 .....                                             | 34 |
| Figure 14. 각 프레임별 딥러닝 모델들의 SSIM 값 비교 .....                                             | 36 |
| Figure 15. 각 딥러닝 모델들의 예측이미지 예시 .....                                                   | 37 |





## List of tables

|                                     |    |
|-------------------------------------|----|
| Table 1. 데이터 요약.....                | 8  |
| Table 2. 각 프레임별 MSE 값 비교 .....      | 31 |
| Table 3. 채 테스트셋에 대한 각 모델 별 성능 ..... | 34 |



# 1. 서론

최근, 신재생 에너지가 세계 전력 공급 에너지원에서 차지하는 부분이 점점 더 커지고 있다. 환경 친화적이라는 신재생 에너지 발전이 갖는 장점은 많은 국가가 지속적으로 관심을 갖고 투자하는 에너지 발전 방식이 될 것으로 예상된다. 많은 종류의 대체 에너지원 중, 특히 태양광 발전은 기술의 발전으로 초기 설치 비용이 지속적으로 감소하고 있고 따라서 대체 에너지원을 장려하는 많은 국가에서 널리 사용되는 대체 에너지 발전 방식 이다. 그러나 기존의 전통적인 에너지 생성 방법과는 달리, 태양광 발전의 큰 단점은 에너지 발전량이 '불안정' 하다는 것이다. 특성이다. 따라서 특정 지역의 에너지 수요는 태양 에너지 등의 불안정한 대체 에너지에 전적으로 의존 할 수 없으며 태양광 발전의 불안정성을 보완하기 위해 대규모 수력 및 화력 발전소를 지속적으로 동시에 운영해야한다. 그러나 전통적인 에너지 발전을 언제 얼마나 작동시킬 것인지를 결정하는 것은 매우 어려운 문제이다. 태양광 발전량이 수요를 충족하기에 불충분한 시기와 부족한 에너지량을 정확하게 예측해야하기 때문이다. 따라서, 생성되는 에너지량이 태양 판넬(전지판)이 받는 일사량에 직접 비례하는 태양광 발전의 특성으로 인하여 일사량에 직접적인 영향을 주는 구름이 특정 영역에 배치되는 시기를 정확히 예측하고자하는 연구가 활발히 이루어지고 있다. 지금까지의 관련 연구는 크게 광학 흐름과 상호 상관의 두 가지로 나눌 수 있다. : Optical flow(광학 흐름 기법), cross-correlation(교차 상관 기법)



광학 흐름 기법은 기존의 컴퓨터 비전 영역에서 움직임을 캡처하는 데 가장 일반적으로 사용되는 기술 중 하나이다. 이 알고리즘은 특정 가정 하에서 다음 제약 조건을 적용하여 모션 필드를 얻는다.

$$0 = u \cdot I_x + v \cdot I_y + I_t, \quad \text{Eq. (1)}$$

여기서  $I$ 는 그레이 스케일로 픽셀 강도 값을 나타내고  $\nabla I(x, t) = (I_x, I_y)$  이다. 또한,  $I_t$ 는 시간  $t$ 에서의  $I$ 의 부분 도함수를 나타낸다.  $(u, v)$ 는 각 픽셀의 움직임 벡터의 속도 크기를 각각  $x$ 와  $y$  방향으로 나타낸 것이다. (Peng et al., 2016).

이 기울기 기반 광학 흐름을 사용하여 구름 이동 방향을 결정하기 위해 수많은 연구가 수행되었다. 우선 Wood-Bradley et al. (2012)는 랩탑 카메라로 촬영한 구름 이미지에 단순히 광학 흐름 방법을 적용하여 구름의 이동 방향을 도출했다. Shi et al. (2011)은 로컬 및 글로벌 광학 흐름의 장점을 모두 활용한다고 주장하는 결합된 로컬-글로벌 광학 흐름을 사용하여 픽셀의 방향 벡터를 구해 구름의 방향 벡터를 획득했다. Chow et al. (2015)는 구름의 역학을 포착하기 위해 비 그리드 모션 광학 흐름 방법인 변형 광학 흐름 방법 (Variational optical flow)을 제안했다. 또한 Idder과 Laachfoubi (2016)는 이미지 의에서 구름을 충분히 나타낼 수 있는 중요한 픽셀을 결정한 뒤, 이 점들이 구름을 충분히 나타내고 있다고 가정하여, 이 점에 Lucas-Kanade의 광학 흐름 방법을 적용하여 구름의 이동 벡터를 계산 하였다. 하지만, 광류 기반 움직임



추정 방법의 세가지 가정 중 하나인 픽셀의 강도가 일정해야한다는 가정은 Clear Sky Index(CSI)가 픽셀 값인 이미지에서는 값이 일정하지 않다. 또한, 광학 흐름 기법은 두 프레임 사이에 큰 움직임이 없다는 가정을 하지만, 우리의 수많은 데이터를 통해 구름이 이동이 광학 흐름 기법의 가정을 충족시키지 않을 만큼 큰 움직임을 가지는 경우가 많다는 것을 확인하였다. 또한, 각 픽셀 단위의 움직임을 구하는 광학 흐름 기법의 경우, 각 픽셀들의 방향 벡터를 합산하여 하나의 큰 구름에 대한 하나의 방향 벡터를 도출하는 데에 어려움이 있다. 따라서 다음 시점의 구름이미지를 생성하는 알고리즘으로 적절하지 않다.

상호 상관 기반 움직임 추정 방법은 움직임을 얻기 위한 기존의 (Block matching technique)블록 매칭 기술에 기초한 기법 중 하나이다. 이 알고리즘은 픽셀 단위로 방향 벡터를 얻지 않고 사용자가 지정한 (window)창 크기 또는 특정 객체 크기에 해당하는 벡터를 얻는 방법이다. 따라서 이 직관적이고 합리적인 알고리즘은 이미지에서 물체의 움직임을 찾아내는 연구에 적극적으로 적용되어 왔고 구름 이동 방향을 도출하는 연구에도 마찬가지로 활발히 적용되어 왔다. 먼저 Hamill과 Nehrkorn (1993)은 사용자가 지정한 창 크기를 블록으로 설정하고 이를 사용하여 두 연속 이미지 사이의 상관 관계가 가장 높은 지역을 통한 구름 이동 방향을 설명했다. Chow et al. (2011)은 표준화된 상호 상관 기법을 사용하여 샌디에고 주변의 지역 구름의 이동 벡터를 도출하였다. 위에서 언급 한 방법들은 사용자가 임의로 창 크기를 하나의 블록으로 설정하기 때문에 구름 크기가 창 크기보다 크면 새로 생성 된 이미지에서 구름이 사



라지거나 찢어 질 가능성이 높다. 이러한 구름 변형 및 소산 문제를 해결하기 위해 Huang et al. (2013)은 각 이미지들 사이의 움직임 벡터를 역추적하고자 했으며 이를 통해 도출한 움직임 트렌드가 미래시점에서는 어떻게 변하는지를 추정하여 이미지 내의 구름의 향후 움직임을 예측하였다. 또한 이 연구는 TSI 이미지 장비를 통해 얻은 정규화 된 구름 이미지에 푸리에 변환을 적용한 뒤, 상호 상관 기법을 사용하여 계산 량이 적은 알고리즘을 구현했다. 그러나 위와 같은 접근 방식은 여전히 계산상 비효율적이며 다양한 시점의 구름 이미지 정보를 활용할 수 없다. 따라서 Peng et al. (2015)은 수정된 방법론 인 Cloud Block Matching technique(구름 블록 매칭 기법)을 제안했다. 이 방법론은 먼저 구름을 감지한 뒤, 기존의 상호 상관 및 광학 흐름 방법과 달리 두 장의 이미지가 아닌 여러 시점의 이미지를 사용하여 구름 이동 방향을 추적하는 새로운 방법을 제안했다.

위에서 언급한 구름의 이동방향을 예측하고자 한 논문들의 프로세스를 요약하면 크게 두가지 단계로 나뉜다. 먼저 이미지 분할 (Image segmentation)과 군집화 (clustering) 과 같은 방법을 이용하여 사진 안의 구름의 영역을 찾는다. 그 다음 첫번째 단계에서 찾은 구름들에 대해서만, 전통적인 컴퓨터 비전 방식 대표적으로 광학 흐름 기법, 교차 상관 기법 등의 방법을 적용하여 픽셀 단위의 방향 벡터를 찾고 이를 이용하여 구름의 이동방향을 찾는다. 하지만 위와 같은 방법은 크게 두가지의 매우 큰 단점이 있다. 첫번째로, 대부분의 기존



연구에서 가정했던 '구름의 모양은 시간에 따라 일정하다'라는 가정은 사실과 매우 다르다는 것이다. 구름의 모양은 시간에 따라 변한다 다시 말해, 찢어지거나 소산할 가능성이 크다는 것이다. 따라서 동일한 구름 두 시점에서 찾아야하는 위의 방법은 적절하지 않다 심지어 본 연구 중에 직접 보았던 수많은 구름 사진은 한 이미지에서 몇개의 큰 구름 덩어리로 나눌 수조차 없는 경우가 매우 많았다. 두번째로, 이동방향을 예측할 때는 항상 인접한 두 시점의 정보만을 이용하여 다음 시점을 예측한다는 점이다. 구름이 조금씩 움직인다는 가정이 있다고 하더라도 이는 충분한 정보를 고려하지 않고 구름의 이동방향을 예측하는 방법이다.

따라서 최근에는 어떠한 전처리와 가정이 필요하지 않으며 가지고 있는 정보를 충분히 활용하여 미래 시점의 이미지를 생성시키는 모델들이 제안되고 있다. 특히, 시계열 분석에 주로 활용되는 순환 신경망 (RNN: Recurrent Neural Network)를 기반으로 한 모델들을 이용한 연구가 활발히 진행되고 있다. [Baseline Model] 언어 모델(language model) 에서 착안을 하되, 이미지에서 특정부분을 패치로 추출하고 이것을 이용하여 미래 시점의 이미지를 만들어냈다. 하지만, 이 모델은 미래의 1시점밖에 생성하지 못한다는 단점이 있었다. 따라서 [FC-LSTM]은 한 개의 인코더(encoder)와 2개의 디코더(decoder)를 가진 모델을 제안하며 미래 긴 시점의 이미지를 생성하는 모델을 제안 하였다. 하지만, FC-LSTM은 완전 연결(fully connected) 알고리즘을 이용하기 때문



에 과거 이미지의 공간 정보가 생성된 이미지에 충분히 이용되지 못한다는 단점이 있다. 이를 극복하기 위해 입력-상태 (input to state), 상태-상태(state to state) 에서 합성곱(convolution)연산을 사용하여 인풋의 공간정보를 충분히 반영하는 알고리즘인 ConvLSTM이 제시 되었다. 이 ConvLSTM 모델을 이용하여 Tropical Cyclone의 미래 위치를 예측하는 연구가 이루어졌으며, 레이다 데이터에 ConvLSTM을 적용하여 한반도영역의 미래의 강수량을 예측하는 연구도 이루어졌다. 또한, 네트워크 깊어질수록 처음 인풋의 정보가 아웃풋에 점점 반영되지 않는다는 ConvLSTM의 단점을 새로운 상태인 Memory state를 추가하여 보완한 모델인 PredRNN이 제시 되었고, PredRNN++의 기울기 소실 문제 (gradient vanishing problem) 문제를 해결한 PredRNN++이 제시되었다.

이 연구에서 우리는 과거의 이미지를 인풋으로 받아 미래의 이미지들을 생성하여 구름의 이동방향을 직관적으로 이해할 수 있게 하는 모델을 제안한다. 본 연구에서 사용한 아이디어는 하루 동안 한반도 주변지역의 일사량 값을 픽셀 값으로 갖는 하나의 이미지를 생성한 뒤, 이를 이어 붙여 하나의 비디오로 정의한다. 그 다음, 특정 시점까지의 일사량 지도를 인풋으로 받아 미래 시점의 일사량 지도를 생성시키는 딥러닝 모델을 학습시켰다. 이 모델이 생성된 일사량 지도를 통해 우리는 구름의 이동방향을 한눈에 직관적으로 확인 할 수 있을 뿐만 아니라, 그 지역의 일사량을 예측함으로써 미래시점동안 특정지역의 태양광 발전으로 발전 가능한 전력량을 추산 할 수 있는 중요한 정보를 얻을 수 있



다.

더욱이 우리는 ConvLSTM, PredRNN, PredRNN++ 세 모델의 아웃풋을 합쳐 3channel로 만들고 이를 U-Net(Ronneberger et al., 2015)의 인풋으로 넣어서 최종적으로 이미지를 생성하는 모델을 구축하였다. 이는 여러 개 learner들의 예측 값을 다시 메타 모델 (meta model)에 학습시켜 최종 테스트 셋에 대한 예측을 하는 스택킹(stacked generalization) 기법을 활용한것으로 본 연구진이 아는 한 이미지에 분야에서 딥러닝 기반의 메타 모델을 사용하여 스택킹 앙상블 기법을 구현한 모델은 없는 것으로 확인하였다. 우리는 cross correlation, FC-LSTM, ConvLSTM, PredRNN, PredRNN++ 과 우리의 모델 사이의 성능 비교실험을 진행하였다. 실험결과, computer vision방법보다 deep learning 방식의 모델이 더 좋은 성능을 보이며, 딥러닝 모델중에서는 본 연구가 제안하는 모델이 가장 좋은 성능을 보이는 것을 확인하였다.

\* 이 학위 논문의 내용은 Solar Energy에 제출된 논문 [Solar radiation map forecasting: Image generation using LSTM-based deep learning in comparison to computer vision]에 포함되어 있음. 내용과 관련한 저작권은 해당 저널이 가지고 있음.





## 2. 데이터 구성 및 전처리

### 2.1 데이터 구성

실험에 사용된 데이터는 2017년 1월 1일부터 2019년 12월 31일까지의 일사량 지도이다. 2017년부터 2018년까지의 데이터는 학습 데이터, 2019년 1월부터 6월은 검증 데이터, 2019년 7월부터 12월은 테스트 데이터로 활용하였다. 학습데이터는 총 1367개의 시퀀스, 검증 데이터, 테스트 데이터는 모두 348개의 시퀀스로 이루어 졌으며 각 시퀀스는 10개의 일사량 지도로 구성되어 있다.

### 2.2 데이터 전처리

원본 데이터의 영역은  $459 \times 636$ 으로 한반도 주변 지역을 나타내지만,  $128 \times 128$  크기로 바꾸어 실험을 진행 하였다. 일사량 지도에서의 각 픽셀 값은 CSI(Clear Sky Index)으로서, 이는 태양의 천정각(COSZ)에 민감한 일반 일사량 값을 표준화하여 보정한 값이다. 일사량 데이터는 15분마다 생성되어 이론적으로는 하루에 약 35개의 일사량 지도를 얻을 수 있지만, 계절에 따라 일사량이 유의미한 값을 가지는 시간의 차이가 있기 때문에 하루에 아침 9시부터 오후 4시까지의 약 20개의 일사량 지도 만을 이용하였다. 10개의 일사량 지도은 5개의 인풋 시퀀스와 5개의 아웃풋 시퀀스로 나누어서 학습을 진행하였다.



Table 1 데이터 요약

| Variable | Description                                  | Dimension         |
|----------|----------------------------------------------|-------------------|
| Lat      | Latitude                                     | 459×636 (128×128) |
| Log      | Longitude                                    |                   |
| GHI      | Global Horizontal Irradiance                 |                   |
| COSZ     | Cosine of Solar Zenith Angle                 |                   |
| CSI      | Clear Sky Index = $GHI/(1370 \times \cos z)$ |                   |




Figure 1: (a): 원본 데이터 영역 및 위성 영상 (b) 본 연구에서 사용한 128×128 사이즈의 일사량 지도 예시



### 3. 방법론

#### 3.1 교차 상관 기법

구름의 이동방향을 도출하고 예측하는 연구는 전통적인 컴퓨터 비전 (computer vision) 영역의 방법을 사용한다. 그 중 대표적인 방법론으로 상호 상관 기법 (cross-correlation) 을 들 수 있다. 본 연구는 이를 직접 구현하여 후에 적용한 딥러닝 알고리즘과 성능 비교를 진행하였다.

구름의 이동방향을 예측하기 위한 교차 상관 알고리즘은 그 종류가 매우 다양하지만, 다음과 같은 공통점이 있다. 1. 연속된 두 시점의 이미지를 사용한다. 2. 두 이미지에서 같은 크기의 영역 (window size) 을 정의하고 두 영역 사이의 correlation 을 구하는 과정을 반복한다. 3. 가장 correlation 이 높은 두 영역을 찾는다. 이 반복 과정을 통해, 이전 시점의 이미지에서의 해당 영역이 다음 시점의 이미지에서 어느 영역으로 이동 하였는지를 구한다.






Figure 2: 교차 상관 기법 프로세스

현재 한국에서 이용되고 있는 위 방법은 오랜시간동안 이용되어온 전통적인 방법이며 매우 직관적이라는 장점이 있지만, 예보하는 시점으로부터 3시간동안의 구름의 이동 벡터가 같은 값이라는 가정을 하고 있어 현실적이지 않다. 더욱이 윈도우 사이즈에 따라 구름의 모양이 심하게 달라지는 경향이 있으며 최악의 경우 하나의 구름이 다음 시점에서는 찢어지는 현상도 발생한다. 따라서 본 연구에서는 먼저 이미지에서 구름을 찾는 과정을 거치고 각 구름의 영역만큼을 window size로 설정하고 상호 상관 기법을 적용하였다.






Figure 3: 향후 5시점 동안 동일한 이동 벡터가 유지되는 현재의 예보시스템

### 3.2 LSTM 기반 딥러닝 모델

Recurrent Neural Network (RNN) 과 Long Short-Term Memory models (LSTM) 계열의 모델은 일반적으로 시계열 데이터를 분석하는 데에 널리 사용되고 있다. 특히 이 모델들은 회귀나 분류 문제를 위해 사용될 뿐 아니라, 인풋 단어를 토대로 새로운 단어를 생성하기 위한 언어 모델링 (language modeling) 분야에서 널리 쓰이고 있다. 언어 모델 특히, n-gram에서처럼 시퀀스를 입력으로 받아 시퀀스를 예측하는 모델들의 기본개념을 수식으로 설명하면 다음과 같다.

$$\tilde{\chi}_{t+1}, \dots, \tilde{\chi}_{t+K} = \underset{\tilde{\chi}_{t+1} \dots \tilde{\chi}_{t+1}}{\operatorname{argmax}} p(\chi_{t+1}, \dots, \chi_{t+k} | \hat{\chi}_{t-J+1}, \hat{\chi}_{t-J+2}, \dots, \hat{\chi}_t), \quad \text{Eq. (2)}$$

where  $\hat{\chi}_1, \hat{\chi}_2, \dots, \hat{\chi}_t$  are the image tensors. (Ranzato, M et al., 2014)



언어모델에서 인풋을 구성하는 하나의 임베딩된 1차원 단어는, 비디오 예측 분야에서는 하나의 2차원의 이미지에 대응되고, 따라서 시퀀스를 인풋으로 받아 이를 토대로 새로운 아웃풋을 만들어 낸다는 점에서 언어 모델과 다음 프레임 예측하는 문제는 상당히 유사하다. 하지만 단순히 인풋을 2차원 벡터로 대체하여 같은 모델을 적용하는 경우 발생하는 문제는 크게 두가지로 나눌 수 있다. 먼저, 2차원 이미지를 수치화(quantize)하기 위한 연산량이 매우 많다는 것이다. 2차원의 이미지의 크기는 일반적으로 1차원 벡터보다 매우 크기 때문에 이 이미지에서 인풋과 전혀 다른 새로운 결과물을 생성하기 위한 유의미한 정보를 뽑아 냄과 동시에 가공하기 쉬운 정도의 크기로 압축하는 문제는 매우 어려운 문제이다. 두번째로, 언어 모델에서의 인풋인 단어 벡터는 공간정보를 가지고 있지 않지만, 이미지는 공간정보를 가지고 있다는 것이다. 따라서 언어 모델에서의 방법을 그대로 비디오 예측 문제에 적용하는 것은 무리가 있다. 그 이후, 위의 문제들을 해결하기 위한 LSTM 기반의 방법론들이 제안되었고 본 연구에서는 FC-LSTM, ConvLSTM, PredRNN 과 PredRNN++를 이용하여 분석을 진행하였다.

### 3.2.1 FC-LSTM

따라서, 위의 문제를 해결하고자 고안된 FC-LSTM은 하나의 인코더와 2개의 디코더 구조를 가진 모델이다. 한 개의 디코더는 오토인코더(Auto-Encoder)에서의 디코더처럼 입력을 재구성하는 역할을 수행하고, 다른 하나의



디코더는 미래 시점의 프레임들을 예측하게 했다. (Ranzato, M et al., 2014)

FC-LSTM은 이를 통해, 오토 인코더의 단점인 인풋의 특징만 외워서 새로운 아웃풋을 생성하는 데에는 어려움이 있다는 것과 가장 최근 몇개의 프레임의 정보만 이용하여 미래를 예측하는 단순 인코더-디코더 구조의 단점을 상호 보완하고자 하였다.




Figure 4: FC-LSTM 아키텍처 (Ranzato, M et al., 2014)

### 3.2.2 ConvLSTM

FC-LSTM는 공간 정보를 고려하지 않는다는 단점이 있다. 따라서 각 이미지의 공간상관(spatial correlation)을 반영하기 위해 ConvLSTM 아키텍처가 고안되었다. (Xingjian et al., 2015) ConvLSTM와 FC-LSTM의 주요 차이점



은 각 셀의 입력 차원이 다르다는 것이다. FC-LSTM에서는 1차원 (1차원 텐서) 입력 데이터만 있으므로 시간적 상관(temporal correlation)을 처리하는데 적합하지만 공간정보를 가지고 있는 데이터에는 적합하지 않다. 특히 FC-LSTM는 시공간 데이터를 처리 할 때 각 셀에 전체 연결이 있는 완전 연결(FC) 알고리즘에 의해 작동되기 때문에 파라미터가 많아 계산복잡도가 높고, 공간적인 정보를 충분히 반영하지 못한다. 반면에, ConvLSTM는 3차원 (3차원 텐서) 입력 데이터를 처리하도록 설계되었다. 각 셀에서의 완전 연결 알고리즘을 합성곱 연산으로 대체하여 인접한 이웃의 입력 및 과거 상태의 공간정보를 반영하여 특정셀의 상태를 결정한다. 이는 계산복잡도를 현격하게 낮추는 효과가 있으며 공간정보를 충분히 반영하는 장점이 있다. (Kim et al., 2018).




Figure 5: ConvLSTM 셀 구조





ConvLSTM 셀 게이트의 관계식은 다음과 같다.

$$\begin{aligned}
 i_t &= \sigma(W_{xi} * \chi_t + W_{hi} * \mathcal{H}_{t-1} + W_{ci} \circ C_{t-1} + b_i) \\
 f_t &= \sigma(W_{xf} * \chi_t + W_{hf} * \mathcal{H}_{t-1} + W_{cf} \circ C_{t-1} + b_f) \\
 C_t &= f_t \circ C_{t-1} + i_t \circ \tanh(W_{xc} * \chi_t + W_{hc} * \mathcal{H}_{t-1} + b_c) \\
 o_t &= \sigma(W_{xo} * \chi_t + W_{ho} * \mathcal{H}_{t-1} + W_{co} \circ C_t + b_o) \\
 H_t &= o_t \circ \tanh(C_t)
 \end{aligned} \tag{Eq. (3)}$$

여기서  $\chi_t$  는 현재 입력 데이터이고,  $\mathcal{H}_{t-1}$  은 이전 단계에서 은닉 상태(hidden state)이며, W 와 b는 학습할 가중치 및 바이어스 행렬이고  $C_t$ 는 현재의 셀 상태이다. " $\circ$ "는 하다마드 곱을 나타내고 " $*$ "는 합성곱 연산을 나타낸다. 시그모이드 함수 ( $\sigma$ )로 인해  $i_t$ ,  $f_t$ , 및  $o_t$ 가 입력, 잊어버림 및 출력 게이트 셀이므로 각 게이트 셀의 확률 값은 0과 1 사이이며 이는 과거의 정보를 얼마나 반영할지를 결정하는 중요한 요소이다. ConvLSTM의 특징인 입력-상태 및 상태-상태 전이에서의 합성곱 연산은 FC-LSTM와의 주요 차이점이며 학습해야 하는 파라미터를 크게 줄이고 시간, 공간적 정보를 효과적으로 모델링 할 수 있다.

### 3.2.3 PredRNN

PredRNN도 마찬가지로 다음 프레임을 예측하는 알고리즘이 가져야하는 특성에 있어서는 ConvLSTM과 큰 골자를 같이 한다. 즉, PredRNN 또한 최대한



깊은 네트워크를 만들어 입력 이미지의 특징을 추출하고자 한다는 점에서는 ConvLSTM과 같다. 하지만 PredRNN은 ConvLSTM이 가지는 문제점을 지적하며 이에 대한 해결책을 제시하였다. (Wang et al., 2017)

PredRNN이 지적한 ConvLSTM의 첫번째 단점은, 셀 상태의 업데이트가 층에 독립적이라는 점이다. 따라서 가장 아래에 있는 층의 정보는 은닉 상태만을 통해서 다음 층으로 전달 되기 때문에, 가장 높은 층에서 가장 아래 있는 층의 정보가 충분히 반영 될 수 없는 구조라는 것이다. 분류 문제처럼 전형적인 지도 학습 관점에서는 다음 층에 정보를 전달할 때, 추상적이고 클래스 편향적인(class specific) 은닉 표현(hidden representation)만이 전달되는 것이 계산 비용 측면에서 효율적이다. 하지만, 미래의 이미지를 예측하여 생성해야하는 비디오 예측 문제에서는 최대한 단계의 층에서의 정보가 종합되어 출력에 반영되어야 한다.

따라서, PredRNN은 새로운 셀 상태 인 메모리 셀(memory cell)을 도입하였다. 이 상태는 은닉 상태와 함께 다음 층으로 수직적으로 업데이트되며 한 시점(time step)의 마지막 상태는 다음 시점 의 첫번째의 층의 입력이 된다. 이 메모리 상태는 특정 시점 에서 입력 에서부터 최종 은닉상태까지 수직적으로 업데이트되기 때문에 공간적인 정보를 가지고 있으며, 이 정보가 수직적으로 깊고, 수평적으로 긴 네트워크에서 소실되지 않도록 하는 기능을 한다.






Figure 6: PredRNN의 구조

PredRNN의 셀 게이트의 관계식은 다음과 같다.

$$\begin{pmatrix} g_t \\ i_t \\ f_t \end{pmatrix} = \begin{pmatrix} \tanh \\ \sigma \\ \sigma \end{pmatrix} W_1 * [\chi_t, H_{t-1}^l]$$

$$C_t^l = f_t \odot C_{t-1}^l + i_t \odot g_t$$

$$\begin{pmatrix} g'_t \\ i'_t \\ f'_t \end{pmatrix} = \begin{pmatrix} \tanh \\ \sigma \\ \sigma \end{pmatrix} W_2 * [\chi_t, M_{t-1}^l]$$

Eq. (4)

$$M_t^l = f'_t \odot M_{t-1}^l + i'_t \odot g'_t$$

$$o_t = \sigma(W_3 * [\chi_t, H_{t-1}^k, C_t^l, M_t^l])$$

$$H_t^l = o_t \odot \tanh(W_4 * [C_t^l, M_t^l])$$

ConvLSTM과 각 기호가 나타내는 의미는 같으며, 메모리 상태( $M$ )가 추가되어 이 상태를 다음 시점에 반영할 정도를 구하기 위한 게이트 연산들이 추가되



었다.

### 3.2.4 PredRNN++

PredRNN에서는 ConvLSTM 의 단점을 극복하고자 시점 사이에 더 복잡한 비선형 변환을 추가하여 공간적인 정보의 순간적인 동적 상태를 모두 잘 보존하고자 메모리 상태를 도입하였다. 하지만 PredRNN은 기울기 소실 문제라는 문제에 직면하였다. 또한 PredRNN++에서는 셀 상태, 메모리 상태를 단순히 채널 별로 합친 뒤  $1 \times 1$  합성곱 연산을 진행하여 최종 층에서는 정보를 합치는 것은 반복 깊이를 높이는 효율적인 방법이 아님을 주장한다. 따라서 PredRNN++에서는 기존의 PredRNN과 두가지의 차별 점을 두어 이 문제들을 해결하고자 하였다. (Wang et al., 2018)

첫번째로, 단순히 채널 별로 합치는것과  $1 \times 1$  합성곱 연산이 아닌, 두 상태 사이에 연속적인(cascade) 함수관계를 만들어 두 정보를 가공하는 처리하는 과정을 추가하였다. 이를 통해 조금 더 효과적으로 정보를 가공하여, 하나의 셀, 층에서도 반복 깊이가 더 깊어지는 효과를 주었다.

두번째로, 기울기 소실 문제를 해결하기 위해 첫번째 은닉층과 두번째 은닉층 사이에 Gradient Highway Unit (GHU) 이라는 information highway를 설치 하였다. 특히, 일시적인 정보를 담고있는 셀 상태가, 입력되는 이미지 시퀀스의 길이가 길어질 수록 초기 입력의 특징을 점점 잊는 경향이 있는데 이를 해결하기 위함이다. 이 것의 기능은 업데이트가 다른 상태에 비해 간소한 z라



는 상태를 새로 도입함으로서, 오래된 입력의 정보를 가장 마지막까지 직접적으로 쉽게 보내는 하나의 경로를 추가한것이다.

GHU를 설치함으로서, 일시적인(Temporal) 정보를 담고있는 셀 상태가 입력 시퀀스의 길이가 길어질 수록 초기의 인풋의 특징을 점점 충분히 반영하지 못하는 문제를 해결하였다. 또한,  $t$ 시점의 정보인  $h_t$ 와 그 전의  $t-1$  시점의 정보인  $z_{t-1}$ 를 가공할 때, 게이트 연산을 통해 내보내기 때문에 각각의 정보를 다음 시점에 얼마나 반영할 것인지까지도 학습한다는 점이 특징이며, 이는 네트워크가 전체 인풋을 최대한 반영할 것인지, 아니면 최근의 인풋을 더 반영할 것인지를 스스로 판단하게 하는 적응 학습(adaptive learning)을 가능하게 하였다.




Figure 7: PredRNN++구조



PredRNN++의 셀 게이트의 관계식은 다음과 같다.

$$\begin{pmatrix} g_t \\ i_t \\ f_t \end{pmatrix} = \begin{pmatrix} \tanh \\ \sigma \\ \sigma \end{pmatrix} W_1 * [\chi_t, H_{t-1}^k, C_{t-1}^l]$$

$$C_t^l = f_t \odot C_{t-1}^l + i_t \odot g_t$$

$$\begin{pmatrix} g'_t \\ i'_t \\ f'_t \end{pmatrix} = \begin{pmatrix} \tanh \\ \sigma \\ \sigma \end{pmatrix} W_2 * [\chi_t, C_t^l, M_{t-1}^k]$$

Eq. (5)

$$M_t^l = f'_t \odot \tanh(W_3 * M_{t-1}^l) + i'_t \odot g'_t$$

$$o_t = \sigma(W_4 * [\chi_t, H_{t-1}^k, C_t^l, M_t^l])$$

$$H_t^l = o_t \odot \tanh(W_5 * [C_t^l, M_t^l])$$



### 3.3 스택킹을 이용한 제안 모델

#### 3.3.1 스택킹 적용 프로세스




Figure 8: 본 연구에서의 스택킹 적용 프로세스,  $G$ 는 입력 이미지 수이고  $N$ 은 출력 이미지 수이다.

LSTM 계열의 딥러닝 모델들은 비디오 예측 분야에서 수치적으로는 좋은 성능을 나타낸다. 그러나 해당 모델들이 생성하는 이미지를 보면 흐릿한(blurry)한 문제가 있다. 특히, 모델이 예측하는 프레임이 많으면 많을수록 이 흐릿한 문제는 더욱 심각해진다. 따라서 본 연구는 이 문제를 해결하기 위해 Stacked Generalization 방법을 이용하여 모델들의 출력을 보정하는 방법을 제안한다. 스택킹은 두가지 절차로 이루어 진다(Wolpert, 1992). 첫 번째로, 다양한 알고



리즘 (Level-0 모델)을 학습하여 모델 출력을 얻는다. 두 번째 단계에서는 첫 번째 단계에서 얻은 결과를 종합하여 메타 학습 세트를(Meta train set) 형성하고 최종 알고리즘 (Level-1 모델)을 사용하여 최종 결과를 예측한다. 이 프로세스를 본 연구에 적용하는 과정을 그림으로 나타내면 Figure8 같다. 레벨 0에서 ConvLSTM, PredRNN 및 PredRNN++은 과거의 이미지 입력 시퀀스로 미래 이미지의 출력 시퀀스를 예측하도록 훈련된다. 그 후 이 모델들의 결과물은 검증 데이터 셋을 예측한다. 3가지 모델의 각 프레임에 대해 예측된 이미지는 채널 별로 합쳐져 3채널 이미지로 변환되고 이 데이터는 메타 트레인 셋으로 정의된다. 레벨 1에서 합성곱 오토인코더는 구성된 메타 트레인 세트의 Ground Truth를 예측하도록 훈련된다. 여기서 얻어진 예측 결과가 본 연구에서의 최종 예측 모델이다. (Ma et al., 2018)

### 3.3.2 메타 모델

스택킹에서 level-1 알고리즘으로 사용된 Convolutional Auto-Encoder의 경우, 인코더 네트워크와 디코더 네트워크, 두 네트워크로 Figure 9에 표시된 아키텍처를 사용한다. 이 모델은 U-Net을 벤치마킹 하였다.

인코딩 네트워크는 전형적인 합성곱 뉴럴 네트워크이며 합성곱 연산을 통해 이미지 기능을 추출하는 프로세스이다. 이 프로세스는 두 개의 3x3 합성곱 연산을 반복하고 연산 이후 활성화 함수는 ReLu를 사용하였다. 또한 2x2 최대 풀링을 통해 다운샘플링을 진행하고 특성 맵을(feature map) 추출한다. 이 과





정에서, 특징 맵 채널은 절반으로 줄어들고, 인코더 네트워크로부터 지속적으로 획득된 특징 맵과 합쳐지며 이 합쳐진 특성맵은 3번의 3x3 합성곱 연산을 거쳐 최종 층에서 하나의 1x1 합성곱 연산을 통해 원래 이미지 크기와 채널을 생성한다.




Figure 9: 메타모델로 사용된 UNet 벤치마킹의 합성곱 오토인코더 구조



## 4. 실험 설계

이전 이미지에서 군집화 알고리즘으로 찾은 구름만의 이동 벡터를 도출하는 교차 상관 방법은, 해당 구름들만을 다음이미지에 반영할 수 있다. 즉, 구름으로 지정되지 않은 많은 지역에서 태양 일사량 값은 다음 시점에서 움직임이 반영되어 나타나지 않는다. 따라서 교차 상관 기법과 딥러닝 알고리즘을 전체 이미지(128×128)에서 픽셀별 MSE를 구하여 성능 비교를 하는 것은 공평하지 않다. (4.1) 이러한 이유로, 본 논문에서는 실험을 두 부분으로 나누었다. 먼저, 교차 상관 방법으로 지정된 구름 영역에 대해서만 구름의 이동 방향을 얼마나 잘 예측하는지 비교했다. (4.2) 그러나, 위의 실험은 이 연구의 목적에 맞지 않으며, 이는 미래의 모든 영역에서 태양 복사량을 예측하는 것이다. 따라서 두 번째로 전체 영역의 일사량 지도를 생성하는 딥러닝 모델에 대한 성능 비교 실험을 수행 하였다. (4.3)

### 4.1 교차 상관 기법 구현

교차 상관 기법을 이용하여 구름의 이동방향을 찾고자 하는 방법론은 군집화나 이미지 분할 알고리즘을 통해 구름의 지역을 찾아내는 것으로부터 시작된다. 따라서 이 방법론을 구현하기 위해 우리도 2번의 군집화 알고리즘을 통해 먼저 구름을 찾았다. 먼저 우리는 각 픽셀의 CSI값을 K-means 군집화 알고리즘을 (Hartigan and Wong, 1979) 사용하여 1차적으로 군집화 진행하였다. 이



를 통해 이미지의 픽셀들이 CSI 값의 범위에 따라 군집이 나뉘지게 되고 이 군집들은 구름의 후보군이 된다. 그러나 단순한 픽셀 값을 이용한 k-means 군집화는 위치정보가 반영되지 않기 때문에 매우 넓은 범위에서 구름이 설정되게 된다. 따라서 설정한 군집에서 픽셀의 위치로만 2차적으로 Hierarchical DBSCAN을 통해 클러스터링을 진행한다. (Campello et al., 2013) Hierarchical DBSCAN는 군집의 개수가 하이퍼 파라미터가(hyper-parameter) 아니기 때문에 밀도에 따라 사진마다 다른 개수의 군집이 설정되게 된다. 설정된 군집 중에서 구름이 아닌 군집을 제거하기 위하여, 각 군집들의 픽셀끼리의 표준편차에 임계치를 설정하였다. 해당 군집의 표준편차가 임계치보다 작은 경우, 해당 군집은 구름이 아니라고 설정하여 상호 상관 알고리즘을 적용하지 않았다. 따라서, 구름은 교차 상관을 사용하여 찾은 방향으로 다음 시점의 이미지에 배치되고 이 과정을 각 구름에 대해 반복하여 다음 시점의 전체 구름 이미지를 생성한 뒤 구름이 위치한 영역의 좌표를 저장한다. 그 후, 실제 이미지에서 이전 단계에서 저장된 좌표에 대응하는 부분을 분리하여 각 알고리즘과의 픽셀 단위의 비교를 진행하였다.

## 4.2 구름의 이동 방향 예측 (CV vs Deep learning)

첫번째 실험에서는 128×128 사이즈의 이미지 전체에 대한 비교를 하는 것이 아니라 교차 상관 기법이 먼저 구름으로 탐지한 부분에 대해서만 성능 비교를 진행하였다. 다시 말해, 구름으로 탐지한 부분에 대해서 교차 상관 기법이



구한 이동벡터만큼 그 다음 시점의 이미지에서 구름을 위치 시키고 그 위치를 저장한다. 그 다음, 그 시점의 Ground Truth 이미지와 딥러닝으로 생성한 이미지에서 저장한 위치의 부분만 따로 떼어낸 뒤, 교차 상관 기법으로 구한 이동 벡터만큼 정말 구름이 잘 이동을 했는지를 구하였다.

먼저 교차 상관 기법의 자체 성능이 어느 정도인지 평가하기 위하여 1번째, 2번째 이미지를 이용하여 도출한 방향 벡터가 미래의 8시점 동안 유지된다고 가정했을 때 얼마나 예보가 정확하게 이루어지는지 평가 하였다.

또한, 또다른 실험은 5개의 이미지를 인풋으로 받아 미래의 5개의 이미지를 생성하는 딥러닝 알고리즘과의 비교를 위해, 교차 상관 방법으로 4번째, 5번째 이미지를 사용하여 계산된 구름의 이동 벡터가 75 분 동안 유지된다는 가정하에 다음 5 개의 시점에 대한 교차 상관을 사용하여 예측 한 구름 이미지를 생성하고 딥러닝이 예측한 다음 5개의 시점에 대한 이미지와 비교 하였다.

### 4.3 일사량 지도 생성

이 실험에서는 앞서 딥러닝 모델들만을 가지고 성능 비교를 진행하였다. 즉, 구름 영역을 따로 떼어서 비교하는 것이 아니라 딥러닝 모델들이 생성한 전체 일사량 지도에 대해 5.1에서 기술할 평가지표를 이용하여 비교 하였다. 특히, FC-LSTM, ConvLSTM, PredRNN, PredRNN ++ 뿐 아니라 본 ConvLSTM, PredRNN, PredRNN++의 예측 이미지를 단순히 평균하여 최



중 결과 이미지를 예측하는 방법과 스택킹 앙상블 기법으로 각 알고리즘의 결과물을 보정하는 모델들의 결과까지 비교 하였다.



## 5. 실험 결과

### 5.1 평가 지표

모델의 성능을 비교하기 위해 비디오 예측 영역에서 가장 일반적으로 사용되는 평가 지표인 MSE (Mean Squared Error), PSNR (Peak Signal-to-Noise Ratio) 및 SSIM (Structural Similarity Index)을 알고리즘 별로 측정하였다.

#### 5.1.1 MSE

평균 제곱 오차 (Mean Squared Error)를 나타내는 MSE는 예측 값과 실제 값 사이의 픽셀 값 차이를 제곱합을 의미한다.

$$MSE = \frac{1}{MN} \sum_{m,n} [I_1(m,n) - I_2(m,n)]^2. \quad \text{Eq. (6)}$$

#### 5.1.2 PSNR

PSNR은 신호가 가질 수 있는 최대 신호에 대한 잡음의 비율을 나타내며 주로 비디오 처리 문제에서 이미지 품질 손실 정보를 평가하는 데 사용된다. PSNR은 로그 스케일로 측정되므로 [db]는 주로 단위로 사용되며 손실이 작을수록 값이 높아진다. 아래 방정식에서 볼 수 있는 R은 입력 이미지의 최대 신호이다



$$PSNR = 10 \log_{10} \left( \frac{R^2}{MSE} \right). \quad \text{Eq. (7)}$$

### 5.1.3 SSIM

SSIM은 딥 모델로 얻은 이미지와 Ground Truth 간의 유사성을 측정하는 인덱스로 비디오 예측 분야에서 MSE 및 PSNR보다 더 정확한 평가 인덱스로 알려져 있다. 이를 구하는 식은 아래 식과 같으며 SSIM의 값 범위는 -1과 1 사이이고 값이 클수록 두 이미지 간의 유사성이 크다는 것을 의미 한다.

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(2\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)}, \quad \text{Eq. (8)}$$

where  $c_1 = (k_1L)^2$ ,  $c_2 = (k_2L)^2$ ,  $L$  is the dynamic range of the pixel values (typically this is  $2^{\text{\#bits per pixel}} - 1$ ),  $k_1 = 0.01$ ,  $k_2 = 0.03$ .

컴퓨팅 환경 구성은 다음과 같다.

- CPU: Intel R Core TM i7-7700 @ 3.60GHZ
- RAM: 64GB DDR4-2666(1333 MHz)
- GPU: NVIDIA TITAN RTX 24GB
- Framework: Python 3.5.2, TensorFlow 1.0, Keras 2.3.0, PyTorch 1.2.0



## 5.2 구름의 이동 벡터 예측 결과

이 실험은 이미지에서 추출한 구름에 대해서 교차 상관 기법이 구한 벡터가 유의미한 벡터인지를 검증하고자 한 실험이다. 따라서 이미지 전체를 복원하는 실험이 아니라는 이 실험의 특성상, 전체 이미지에 대한 비교가 이루어질 수 없다. 즉 따라서 비디오 예측 문제에서 사용하는 평가 지표가 아닌 단순 MSE 를 통해 알고리즘의 성능을 비교하였다.

Table 2: 각 프레임별 MSE 값 비교

| Model             | Frame1 | Frame2 | Frame3 | Frame4 | Frame5 |
|-------------------|--------|--------|--------|--------|--------|
| Cross-correlation | 0.069  | 0.075  | 0.080  | 0.086  | 0.088  |
| FC-LSTM           | 0.018  | 0.019  | 0.02   | 0.022  | 0.023  |
| ConvLSTM          | 0.003  | 0.006  | 0.009  | 0.014  | 0.021  |
| PredRNN           | 0.003  | 0.006  | 0.008  | 0.01   | 0.013  |
| PredRNN++         | 0.003  | 0.005  | 0.007  | 0.009  | 0.011  |

Table 2 에서 알 수 있듯이, 교차 상관 기법의 MSE 가 가장 높은 것을 알 수 있다. 이는 이 알고리즘으로 도출한 방향 벡터가 부정확하다는 것을 의미하고 구름의 움직임을 제대로 포착 및 예측 하지 못한다는 것을 의미한다. 특히, 더 먼 미래의 시점을 예측할수록 교차 상관 기법과 딥러닝 모델들 사이의 성능의 차이가 더 커짐을 알 수 있다. 이 결과를 통해 미래에 구름의 이동 방향이 과거의 이동 방향과 동일 할 것이라는 상호 상관의 가정이 현실





에 맞지 않는다는 것을 알 수 있다. 딥러닝 모델들은 대체적으로 우수한 성능을 나타내고 그 중에서는 PredRNN++가 가장 좋은 성능을 보이는 것을 확인할 수 있다. 이를 통해 딥러닝 모델들이 이미지 내의 물체의 움직임을 잘 이해하고 예측하고 있음을 알 수 있다.




Figure 10: 교차 상관 기법 vs 딥러닝 모델






Figure 11 첫번째, 두번째 이미지를 이용하여 구한 벡터가 미래의 8시점 동안 유지된다고 가정한 뒤 구한 각 프레임별 MSE 평균

### 5.3 일사량 지도 생성 결과

이 실험은 각 딥러닝 모델들이 과거 5시점의 일사량 지도를 입력으로 받아, 미래 5시점의 일사량 지도를 생성하는 실험으로 한반도 지역 전체의 일사량 값을 이미지 생성을 통해 예측한다. 5.1에서 기술한 각 평가지표들에 대하여 딥러닝 모델들의 결과물을 평가 하였다.



Table 3: 전체 테스트셋에 대한 각 모델 별 성능

| Model                         | MSE           | PSNR         | SSIM         |
|-------------------------------|---------------|--------------|--------------|
| FC-LSTM                       | 0.0207        | 38.79        | 0.648        |
| ConvLSTM                      | 0.0111        | 47.02        | 47.02        |
| PredRNN                       | 0.008         | 48.54        | 0.840        |
| PredRNN++                     | 0.0075        | 49.47        | 0.850        |
| Averaged Model                | 0.0071        | 50.41        | 0.851        |
| <b>Stacked Generalization</b> | <b>0.0068</b> | <b>50.66</b> | <b>0.862</b> |

Table 3은 테스트 데이터 전체에 대해서 각 모델들의 예측 정확도를 나타낸 표이다. FC-LSTM은 모든 평가 지표에서 가장 안좋은 예측 성능을 나타내고 PredRNN++가 단일모델로는 가장 좋은 성능을 나타낸다. 이는 Figure 12, 13, 14에서도 확인 할 수 있다.

본 연구 중에 FC-LSTM을 제외한 나머지 3개의 모델, ConvLSTM, PredRNN, PredRNN++ 모델들의 결과 이미지를 단순히 평균하는 것만으로도 어떠한 단일모델보다 좋은 성능을 나타내는 것을 확인하였다. (Table 3) 따라서 단일모델의 결과물을 좀 더 효율적으로 종합하는 방법을 찾고자 하였고 이는 (3.3)에서 설명하였듯이 스택킹을 이용한 앙상블 기법을 적용하여 실험을 수행하였다. 예상 했던 대로, 제안 모델의 성능이 가장 좋았다.






Figure 12: 각 프레임별 딥러닝 모델들의 MSE 비교




Figure 13: 각 프레임별 딥러닝 모델들의 PSNR 비교






Figure 14: 각 프레임별 딥러닝 모델들의 SSIM 비교

특이 사항으로는 ConvLSTM의 성능이 마지막 두 시점에서 일관되게 안좋아지는 것을 확인 할 수 있었다. 이는 PredRNN, PredRNN++에서 지적한 기울기 소실 문제로 인한 것으로 추측된다. 또한, Figure 15 에서 확인 할 수 있듯이 PredRNN의 결과가 실제 이미지와 형태적인 측면에서는 가장 흡사한것으로 나타난다. 하지만 MSE, PSNR, SSIM과 같은 수치적인 평가지표에서는 가장 좋은 모델은 아닌 것으로 확인된다. 이는 물체의 형태는 디테일 하게 잘 예측하지만, 픽셀값까지는 잘 예측하지 못하는 것이라고 해석할 수 있다.






Figure 15: 각 딥러닝 모델들의 예측이미지 예시



## 6. 결론

이 연구의 목적은 표준화 된 태양 복사 픽셀 값 (CSI)의 이미지를 사용하여 구름의 움직임을 예측함과 동시에 미래의 일사량 지도를 생성하는 것이다. 첫 번째 실험에서는 구름 이동 벡터를 기존의 컴퓨터 비전 방법인 교차 상관 기법을 구현하여 계산하였고, 이 벡터를 사용하여 미래 시점의 일사량 지도를(구름의 이미지)생성하였다. 그러나 교차 상관 기법은 알고리즘을 적용하기 전에 이미지에 구름을 찾아야한다는 단점이 있으며, 이 알고리즘은 이미지에 구름이 많지 않거나 구름이 서로 명확하게 구별되는 경우에만 작동한다. 또한 구름의 이동방향을 도출하는 과정에서 2개의 연속적인 이미지 밖에 사용되지 않기 때문에 사용 가능한 정보를 충분히 사용하지 않는다. 위의 단점을 극복하기 위하여 우리는 과거의 데이터를 충분히 활용하여 미래의 구름 이미지 및 일사량 지도 전체를 생성하여 예측하는 모델을 구축하고자 했다.

각각 다르게 설계된 두가지의 실험을 통해 교차 상관 기법보다 딥러닝 모델들이 이미지내 구름의 이동 방향 및 정도를 더 잘 예측하는 것을 확인 할 수 있었으며, 이후 다음 실험에서 예측된 5 개의 프레임에 대한 정량적 평가에 의해, 스택킹 앙상블을 적용한 모델이 모든 평가 지표에서 좋은 성능을 나타내는 것을 확인하였다.

특히, 본 연구는 픽셀의 이동 벡터를 찾아내어 픽셀 단위의 일사량의 변화



를 예측하는 것이 아니라, 미래 시점의 일사량 지도를 한번에 생성시켜 전체 영역의 일사량을 정확히 예측하였다. 본 연구진의 아는 한, 일사량 맵 전체를 한번에 모델로 생성시켜 일사량과 일사량 변화를 예측한 연구는 없다. 실험을 통해 확인된 딥러닝 모델의 우수한 성능은 기존의 컴퓨터 비전 방식의 일사량 예보를 대체할 수 있는 충분한 가능성을 보여준다. 따라서, 본 연구를 통해 더 효율적인 에너지 발전을 위한 일사량 예보가 가능함을 확인하였으며 추후 원본 위성영상 사이즈의 예측이 이루어진다면 더 의미 있는 예보가 가능해 질것으로 생각된다.





## 참고 문헌

- [1] Campello, R.J., Moulavi, D., Sander, J., 2013. Density-based clustering based on hierarchical density estimates, in: Pacific-Asia conference on knowledge discovery and data mining, pp. 160-172.
- [2] Chow, C.W., Belongie, S., Kleissl, J., 2015. Cloud motion and stability estimation for intra-hour solar forecasting. *Solar Energy* 115, 645-655.
- [3] Chow, C.W., Urquhart, B., Lave, M., Dominguez, A., Kleissl, J., Shields, J., Washom, B., 2011. Intra-hour forecasting with a total sky imager at the UC San Diego solar energy testbed. *Solar Energy* 85, 2881-2893.
- [4] Hamill, T.M., Nehrkorn, T., 1993. A short-term cloud forecast scheme using cross correlations. *Weather and Forecasting* 8, 401-411.
- [5] Hartigan, J.A., Wong, M.A., 1979. Algorithm AS 136: A k-means clustering algorithm. *Journal of the Royal Statistical Society. Series C (Applied Statistics)* 28, 100-108.
- [6] Huang, H., Xu, J., Peng, Z., Yoo, S., Yu, D., Huang, D., Qin, H., 2013. Cloud motion estimation for short term solar irradiation prediction, in: 2013 IEEE International Conference on Smart Grid Communications (SmartGridComm), pp. 696-701.
- [7] Idder, H.I.B., Laachfoubi, N., 2016. Cloud Motion Estimation in Satellite Image Sequences by Tracking Skeleton Critical Points Using Lucas-Kanade Method, in: 2016 13th International Conference on Computer Graphics, Imaging and Visualization (CGiV), pp. 178-183.
- [8] Kim, S., Kang, J.S., Lee, M., kwang Song, S., 2018. DeepTC: ConvLSTM Network for Trajectory Prediction of Tropical Cyclone using Spatiotemporal Atmospheric Simulation Data.



- [9] Ma, Z., Wang, P., Gao, Z., Wang, R., Khalighi, K., 2018. Ensemble of machine learning algorithms using the stacked generalization approach to estimate the warfarin dose. *PloS one* 13.
- [10] Peng, Z., Yu, D., Huang, D., Heiser, J., Kalb, P., 2016. A hybrid approach to estimate the complex motions of clouds in sky images. *Solar Energy* 138, 10–25.
- [11] Peng, Z., Yu, D., Huang, D., Heiser, J., Yoo, S., Kalb, P., 2015. 3D cloud detection and tracking system for solar forecast using multiple sky imagers. *Solar Energy* 118, 496–519.
- [12] Ranzato, M., Szlam, A., Bruna, J., Mathieu, M., Collobert, R., Chopra, S., 2014. Video (language) modeling: a baseline for generative models of natural videos. *arXiv preprint arXiv:1412.6604*.
- [13] Ronneberger, O., Fischer, P., Brox, T., 2015. U-net: Convolutional networks for biomedical image segmentation, in: *International Conference on Medical image computing and computer-assisted intervention*, pp. 234–241.
- [14] Shi, J.L., Bai, S.Q., Si, J.W., 2011. Analysis and research of cloud motion based on CLG optical flow. *Computer Technology and Development* 21, 135–138.
- [15] Srivastava, N., Mansimov, E., Salakhudinov, R., 2015. Unsupervised learning of video representations using lstms, in: *International conference on machine learning*, pp. 843–852.
- [16] Ting, K.M., Witten, I.H., 1997. Stacked Generalization: when does it work? .
- [17] Wang, Y., Gao, Z., Long, M., Wang, J., Yu, P.S., 2018. Predrnn++: Towards a resolution of the deep-in-time dilemma in spatiotemporal predictive learning. *arXiv preprint arXiv:1804.06300*.
- [18] Wang, Y., Long, M., Wang, J., Gao, Z., Philip, S.Y., 2017. Predrnn: Recurrent neural networks for predictive learning using spatiotemporal lstms, in: *Advances in Neural Information Processing Systems*, pp. 879–888.
- [19] Wolpert, D.H., 1992. Stacked generalization. *Neural networks* 5, 241–259.



[20] Wood-Bradley, P., Zapata, J., Pye, J., 2012. Cloud tracking with optical flow for short-term solar forecasting.

[21] Solar Thermal Group, Australian National University, Canberra, Australia .

[22] Xingjian, S.H.I., Chen, Z., Wang, H., Yeung, D.Y., Wong, W.K., chun Woo, W., 2015. Convolutional LSTM network: A machine learning approach for precipitation nowcasting, in: Advances in neural information processing systems, pp. 802-810.

